

Ampliación exposición TFG (Métodos del descenso)

Óscar Climent Ivorra

Trabajo Fin de Grado
Grado en Matemáticas

11 de junio de 2026

Índice

- 1 Descenso del gradiente (GD)
- 2 Descenso del gradiente estocástico (SGD)
- 3 Descenso del gradiente estocástico por mini-lotes (mini-batch SGD)

Índice

- 1 Descenso del gradiente (GD)
- 2 Descenso del gradiente estocástico (SGD)
- 3 Descenso del gradiente estocástico por mini-lotes (mini-batch SGD)

Descenso del gradiente (GD)

El descenso del gradiente actualiza los pesos en la dirección contraria al gradiente del error de entrenamiento.

Después de elegir al azar un valor inicial $\mathbf{w}^{(0)}$ para el vector de parámetros $\mathbf{w}$, el valor de $\mathbf{w}$ se actualiza con el siguiente proceso iterativo:

Proceso iterativo

$$\mathbf{w}^{(\tau)} = \mathbf{w}^{(\tau-1)} - \eta_{\tau} \nabla R(\mathbf{w}^{(\tau-1)}), \quad \tau = 1, 2, 3, \dots,$$

donde τ representa la iteración y η_{τ} el tamaño de paso de la iteración τ .

Después de cada iteración, se vuelve a calcular el gradiente para el nuevo vector de parámetros $\mathbf{w}^{(\tau)}$ y se repite el proceso hasta alcanzar un número de iteraciones o criterios de parada:

$$\|\nabla R(\mathbf{w}^{(\tau)})\| < \epsilon \quad ; \quad \|\mathbf{w}^{(\tau)} - \mathbf{w}^{(\tau-1)}\| < \tilde{\epsilon} \quad ; \quad \|\nabla R(\mathbf{w}^{(\tau)}) - \nabla R(\mathbf{w}^{(\tau-1)})\| < \tilde{\tilde{\epsilon}}$$

Existen métodos más sofisticados como el algoritmo AdaGrad, RMSProp o Adam, en los cuales el tamaño de paso es posiblemente distinto y disminuye de forma adaptativa para cada uno de los parámetros del vector $\mathbf{w}$.

El método del descenso del gradiente evalúa en cada iteración todo el conjunto de datos de entrenamiento y es muy costoso.

Índice

- 1 Descenso del gradiente (GD)
- 2 **Descenso del gradiente estocástico (SGD)**
- 3 Descenso del gradiente estocástico por mini-lotes (mini-batch SGD)

Descenso del gradiente estocástico (SGD)

$R(\mathbf{w})$ es la suma de N_{train} términos $R_n(\mathbf{w})$, cada uno relativo a una observación del conjunto de entrenamiento

$$R(\mathbf{w}) = \sum_{n=1}^{N_{train}} R_n(\mathbf{w})$$

Proceso iterativo

$$\mathbf{w}^{(\tau)} = \mathbf{w}^{(\tau-1)} - \eta_{\tau} \nabla R_n(\mathbf{w}^{(\tau-1)}), \quad \tau = 1, 2, 3, \dots,$$

donde τ representa la iteración y η_{τ} el tamaño de paso de la iteración τ y $\nabla R_n(\mathbf{w})$ es el gradiente del término $R_n(\mathbf{w})$ del error de entrenamiento correspondiente a la observación n -ésima, $n \in \{1, \dots, N_{train}\}$.

Las iteraciones necesarias para procesar todo el conjunto de entrenamiento recibe el nombre de **época de entrenamiento**. Se realizan aproximaciones del gradiente malas.

Índice

- 1 Descenso del gradiente (GD)
- 2 Descenso del gradiente estocástico (SGD)
- 3 Descenso del gradiente estocástico por mini-lotes (mini-batch SGD)

Descenso del gradiente estocástico por mini-lotes (mini-batch SGD)

Es una solución intermedia de los dos métodos mencionados anteriormente.

La aproximación del error de entrenamiento basada en $\mathcal{B}_\tau$ (**mini-lote**), $R_{\mathcal{B}_\tau}(\mathbf{w})$, se define como la media aritmética de los términos $R_n(\mathbf{w})$ del error de entrenamiento, correspondientes a las B observaciones en $\mathcal{B}_\tau$,

$$R_{\mathcal{B}_\tau}(\mathbf{w}) = \frac{1}{B} \sum_{n \in \mathcal{B}_\tau} R_n(\mathbf{w})$$

El vector de parámetros $\mathbf{w}$ se actualiza de la forma siguiente:

Proceso iterativo

$$\mathbf{w}^{(\tau)} = \mathbf{w}^{(\tau-1)} - \eta_\tau \nabla R_{\mathcal{B}_\tau}(\mathbf{w}^{(\tau-1)}), \quad \tau = 1, 2, \dots,$$

donde $\nabla R_{\mathcal{B}_\tau}(\mathbf{w})$ es la aproximación del gradiente total obtenido utilizando el mini-lote $\mathcal{B}_\tau$.

Conclusión final

Gracias por su atención